多方法融合的微博信息级联传播研究：可视化、宏观与微观预测系统

李哲伟　章一诺　王卓熙

2026 年 1 月 9 日

摘要：社交媒体中的信息级联传播是网络科学与计算社会科学的重要研究课题。本文以微博平台为例，构建了一个集可视化分析、宏观趋势预测与微观机制建模于一体的多方法融合研究框架。首先，通过可视化技术对信息传播的网络结构、时空特征和演化模式进行直观呈现与探索性分析。其次，在宏观层面，基于时间序列与用户节点特征，建立了信息传播规模的预测模型，实现了对热点话题传播趋势的提前感知。最后，在微观层面，通过节点级预测模型分析个体用户的转发决策行为，揭示了信息级联形成的微观机制。实验结果表明，本研究所提出的多方法框架能够从不同维度有效理解和预测微博信息级联传播现象，为舆情监测、内容推荐和传播干预提供了系统的分析工具与理论依据。

关键词：信息级联；转发树；可视化；微博；传播预测；机器学习

1　简介

信息级联预测作为理解社交媒体动态、舆情演化及信息传播规律的关键任务，近年来随着深度学习技术的快速发展取得了显著进展。为了系统梳理这一领域的研究脉络与方法体系，Wang 等人（2024）在《Symmetry》期刊上发表了题为《基于深度学习的信息级联预测综述》的论文。该综述从预测目标与预测方法两个维度构建了全新的双层分类框架：按预测目标可分为微观级联预测（关注节点层面传播行为）、宏观级联预测（关注整体传播规模）以及多尺度级联预测（融合微观与宏观视角）；按预测方法则划分为基于拓扑结构、基于内容以及基于大模型的三类主流技术路径。文章系统回顾了各类代表性模型（如 GNN、Transformer、Hawkes 过程与深度学习结合模型等），总结了常用数据集与评估指标，并深入探讨了其在公共卫生、危机管理、市场营销等领域的实际应用。最后，作者指出未来研究应聚焦于多模态信息融合、时序动态与实时预测、大模型可解释性以及社交网络异构结构建模等关键方向。[1] 该综述为我们理解当前信息级联预测的研究现状、方法演进及应用前景提供了全面而清晰的指引，也为本研究在特征工程、模型构建与结果分析等方面提供了重要的理论基础与方法参考。

2　数据获取与处理

本研究的数据来源于新浪微博平台，核心数据对象为完整的微博转发树（即包含原始微博及所有转发节点及其关系的树状结构）。我们采用基于 Python 的爬虫框架进行数据采集。由于微博平台严格的反爬机制，包括请求频率限制、动态验证码及登录状态检测等，加之项目周期的时间约束，本研究所获取的数据在规模上进行了聚焦。

首先，我们爬取了若干条微博的完整转发树作为信息级联可视化部分的研究对象，旨在直观展示信息传播的拓扑结构与时空演化模式。其次，为进行宏观层面的传播趋势预测，我们扩充了数据规模，采集了约 100 条微博转发树，该集合涵盖了不同话题、不同传播规模的事件，以用于构建和训练预测信息传播广度和速度的宏观模型。最后，为深入探究信息传播的微观机制与用户转发行为，我们从已采集的数据中精心筛选出 30 条社交网络结构复杂、具有代表性的转发树，作为微观预测研究的核心数据集。不仅如此，为增强微观预测模型对社交影响力扩散的刻画能力，我们针对这 30 条转发树中的所有参与用户，额外爬取了其“相互关注”关系数据，从而构建了用于预测用户转发概率的底层社交关系子图。

3 信息级联可视化

3.1 信息热度分布与时间演化曲线

以“南京大学食堂帝王蟹”为例，基于所采集的数据绘制相关图像。图 1中的第一张子图展示了该条微博的转发量随时间变化的曲线，整体呈现近似多项式函数形态：发布后不久转发量即进入快速增长阶段，随后增速逐渐放缓，最终趋于稳定。图 1中的第二张子图展示了信息热度随时间的变化曲线，其中热度由窗口期内的转发量、参与转发用户数、平均传播深度、影响地区数量以及深层传播占比等多项特征线性加权计算得出，能够更综合地反映信息传播的动态特征。该曲线与图一趋势相符，即信息发布后热度迅速攀升至峰值，随后逐渐衰减。通过分析其他微博样本发现，信息热度-时间曲线大多呈现单峰形态，少数呈现双峰或多峰结构。图 1中的第三张子图为累计影响地区随传播时间的变化情况，可见微博的传播范围随时间推移逐步扩大。

3.2 传播结构：转发树可视化

图 2a与 2b分别展示了两个代表性案例的转发树结构。其中，图四对应“雅安地震贪污天价耳环事件”，转发量在万级；图五对应“国家公祭日”相关微博，转发量达百万级。两图均采用扇形图示直观呈现了信息传播的树状分叉特征。

基于对多例微博转发结构的分析，我们得到结论一：传统传播学理论在一定程度上仍适用于当前社交媒体环境；同时，具有争议性或易于激发情绪的话题往往具备更深层次传播的潜力。

3.3 转发量与传播深度的分布特征

图 3a与图 3b分别以扇形图形式呈现了上述两个案例中转发量在不同传播深度上的分布情况。在研究中我们发现，不少微博如“国家公祭日”案例所示，其二级转发量高于一级转发量。进一步分析后，我们得出结论二：微博平台中显著的“饭圈化”现象催生了此类反常传播结构。明星效应及其粉丝的跟风行为、数据刷量等实践，导致了二级传播量反超一级传播量等非常规传播模式的出现。

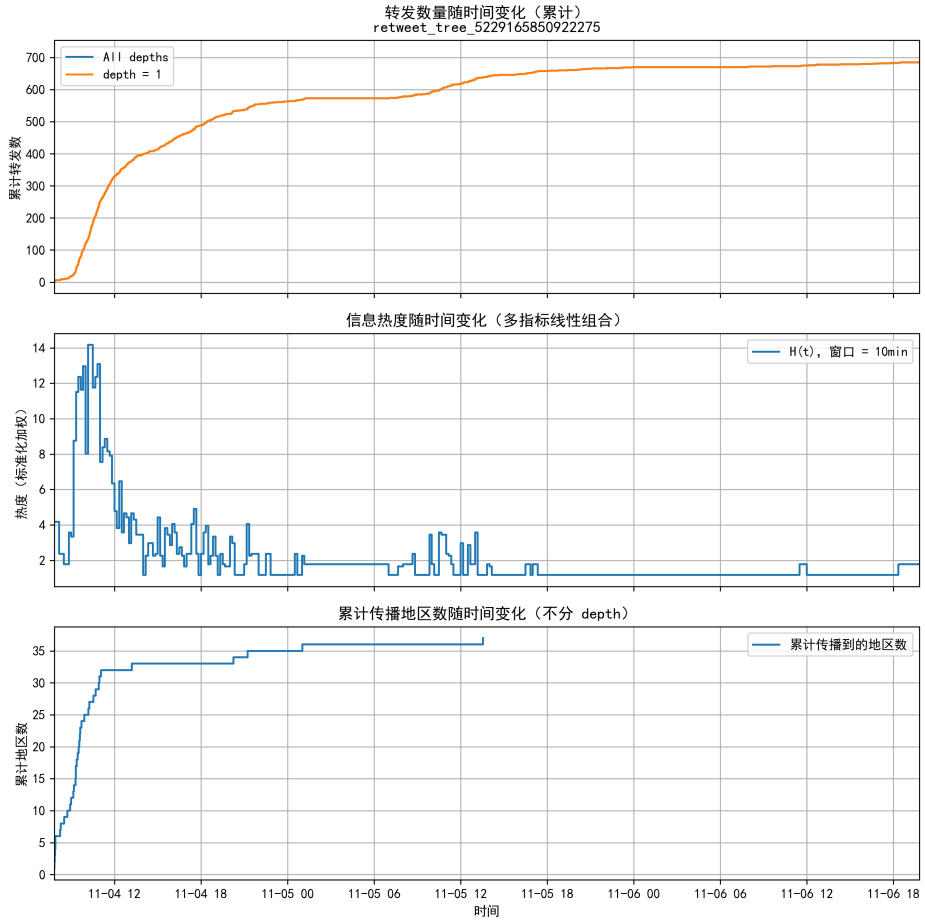

图 1: 信息热度分布与时间演化曲线

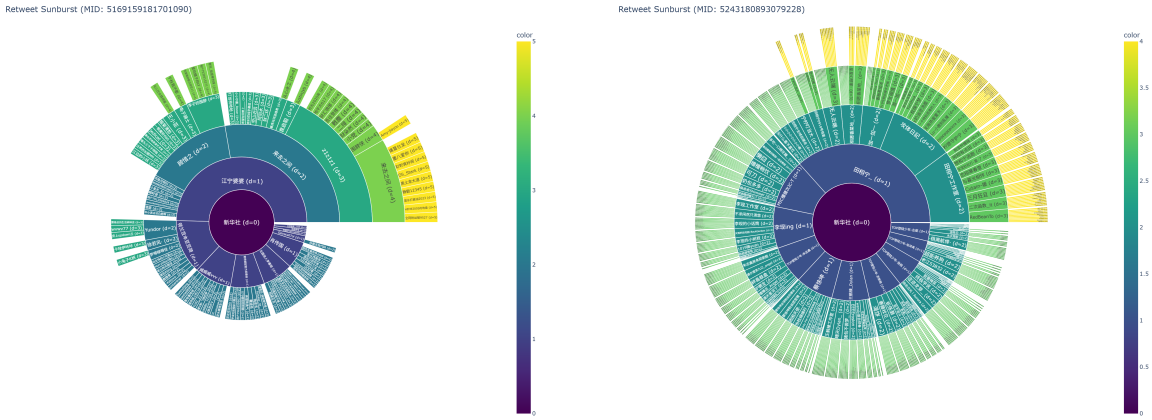

(a) “雅安地震贪污天价耳环事件”　　(b) “国家公祭日”

图 2: 两起事件的转发树旭日图对比

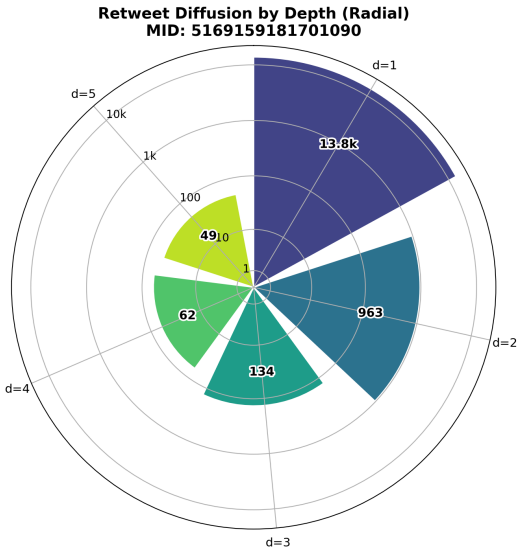

(a) “雅安地震贪污天价耳环事件”

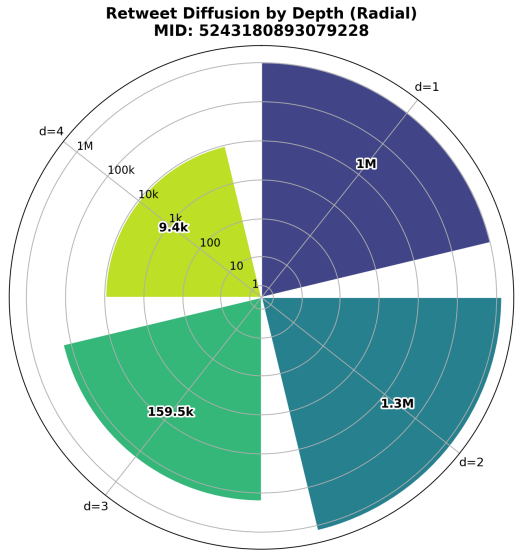

(b) “国家公祭日”

图 3: 两起事件的转发树深度分布图对比

4 微博级联传播宏观预测

4.1 任务概述

本部分旨在基于信息早期传播的特征，建立机器学习模型以预测其未来的最终转发量。该任务可形式化为一个回归问题：输入为一条微博在观测窗口内的传播级联序列及相关属性特征，输出为对该微博最终累计转发量的预测值。研究选择转发量作为预测目标，因其能直观反映信息传播的广度与影响力。为减少极端值影响并改善模型拟合效果，对目标变量采用 $\log(1+x)$ 变换。模型评估采用均方根误差（RMSE）、平均绝对误差（MAE）与决定系数（R^2）三项指标。[2]

4.2 数据处理

为构建预测模型，我们从新浪微博平台爬取了 100 条转发量介于 200 至 500 之间的微博，每条微博对应的完整转发记录构成一棵” 转发树”。每条样本包含以下多维度信息：

- **初始微博属性**：发布者 ID、发布时间、用户粉丝数、认证状态等。
- **转发级联序列**：按时间顺序排列的转发记录，每条记录包含转发用户、转发时间、父节点 ID、传播深度等。
- **转发者画像**：每位转发用户的粉丝数、认证状态等影响力相关属性。

基于上述原始数据，在设定的 2 小时观测窗口内提取了以下五类特征用于模型训练：

1. **基础统计特征**：窗口内累计转发量 (`n_obs`)、转发时间间隔的统计量（均值、标准差、最小值、最大值、十分位数 `q_10`、中位数 `q_50`、九十分位数 `q_90`）。
2. **时间动力学特征**：达到第 5、10、20 次转发的时间 (`time_to_5h`、`time_to_10h`、`time_to_20h`)、突发性指标 (`interval_burstiness`)、时间窗内的分段转发增量（将 2 小时分为 12 段，每段 10 分钟）。

3. **树结构特征**：最大传播深度 (`max_depth`)、平均深度 (`mean_depth`)、深度分布的熵 (`depth_entropy`)、最大出度 (`max_out_degree`)、前 5 大出度的平均值 (`top5_mean_out_degree`)、出度分布的基尼系数 (`gini_out_degree`) 和赫芬达尔指数 (`hhi_out_degree`)。

4. **转发者影响力特征**：log(1+粉丝数) 的最大值 (`max_log_followers`)、平均值 (`mean_log_followers`)、前 5 大平均值 (`top5_mean_log_followers`)、最大影响力节点出现时间 (`time_of_max_follower_h`)、认证用户比例 (`verified_ratio`)、前 10 条转发中的认证用户数 (`verified_early10`)。

5. **其他特征**：原微博作者粉丝数的对数值 (`root_log_followers`)、作者认证状态 (`root_verified`)、发布时间的小时 (`pub_hour`)、星期 (`pub_weekday`)、是否周末 (`pub_is_weekend`)、是否夜间 (`pub_is_night`) 等。

4.3 模型建立

本研究选用 XGBoost（Extreme Gradient Boosting）作为预测模型。[3]XGBoost 是一种高效的梯度提升树实现，通过加法集成多棵回归树来提升预测性能。对于第 k 棵树，模型对样本 x_i 的预测值为：

$$\hat{y}_i^{(k)} = \sum_{j=1}^{k} f_j(x_i) = \hat{y}_i^{(k-1)} + f_k(x_i) \tag{1}$$

在每一轮迭代中，通过最小化以下目标函数来学习第 k 棵树：

$$\text{obj}^{(k)} \approx \sum_{i=1}^{n} \left[L(y_i, \hat{y}_i^{(k-1)}) + g_i f_k(x_i) + \frac{1}{2} h_i f_k^2(x_i) \right] + \Omega(f_k) \tag{2}$$

其中 $g_i = \partial_{\hat{y}_i^{(k-1)}} L(y_i, \hat{y}_i^{(k-1)})$ 和 $h_i = \partial^2_{\hat{y}_i^{(k-1)}} L(y_i, \hat{y}_i^{(k-1)})$ 分别为损失函数 L 对 $\hat{y}_i^{(k-1)}$ 的一阶和二阶导数，$\Omega(f_k)$ 为正则化项，用于控制模型复杂度以防止过拟合。

模型采用以下超参数设置：树的数量 ($n_estimators$) 为 3000，学习率 ($learning_rate$) 为 0.03，最大深度 (max_depth) 为 6，行采样率 ($subsample$) 和列采样率 ($colsample_bytree$) 均为 0.8，$L2$ 正则化项 (reg_lambda) 为 1.0。为防止过拟合，设置早停机制 ($early_stopping_rounds = 120$)。

数据集按 8:2 的比例随机划分为训练集和测试集。训练集进一步划分为训练子集和验证集（比例 8:2），验证集用于监控模型性能并实现早停。所有数据划分均设置固定随机种子 ($random_state = 312$) 以确保结果可复现。

4.4 结果分析

基于所提取的早期传播特征，使用 XGBoost 回归模型对微博转发量进行预测。预测目标为经过 $\log(1+x)$ 变换后的最终抓取转发量（meta_crawled_retweets）。模型评估采用均方根误差（RMSE）、平均绝对误差（MAE）与决定系数（R^2）三项指标。

实验结果显示，在测试集上，模型对 $\log(1+x)$ 变换后目标值的预测取得了较为理想的效果，RMSE 与 R^2 分别为 **0.2047** 与 **0.6001**。将预测值反变换至原始尺度后，模型对最终抓取转发量的 RMSE 和 R^2 为 **57.9110** 和 **0.5877**。这表明，基于两小时早期传播特征所构建的模型，能够在一定程度上预测微博的最终传播规模。

模型分析亦揭示了一些误差较大的异常样本，其成因可能包括：1）特定“饭圈化”事件引发的非线性爆发式传播；2）观测窗口（2 小时）后发生的相关特定事件对传播路径的二次冲击；3）

因数据抓取限制导致的 coverage 偏低或不完整，影响了目标的真实性与特征的表征能力。4）在利用早期数据预测最终转发量的任务设定下，早期数据可能由于微博发布时间等等数据不够充分。这些现象为后续模型的改进指出了方向。

5 微博传播级联微观预测

5.1 问题设定

微观预测问题中，需要完成的任务为在时间步 t，基于前 t 个观察到的转发情况，预测下一个参与转发的用户。其中输入设每个级联对应一个有向社交图 $G = (V, E)$ 其中 V 表示参与该级联的用户集合，E 表示社交网络中的关注关系。同时该级联具有一条传播序列 $S = (u_1, u_2, \ldots, u_T)$，其中 u_1 表示根用户（root）。模型的目标是在给定前 t 个已发生用户 $(u_1, \ldots, u_t)$ 的条件下，预测下一个传播用户 u_{t+1}。项目中采用了一种结合图神经网络（GNN）与序列模型（LSTM）的级联传播预测方法，用于在给定部分传播历史的条件下预测下一位最可能参与传播的用户，本模型同时建模了社交结构依赖与时间序列依赖。[2]

5.2 算法流程

模型的整体算法流程如下所示，其中模型以历史级联序列与社交网络结构作为输入，通过联合建模用户关系与传播动态来预测下一步可能被激活的用户节点。

1. **输入构建**：对于每个级联，给定其前 t 个时间步的激活用户序列 $(u_1, \ldots, u_t)$ 以及对应的社交网络结构 $G = (V, E)$。其中，序列刻画了信息传播的时间演化过程，而社交网络刻画了用户之间的潜在影响关系。

2. **社交关系编码（GNN）**：将社交网络输入图神经网络，对每个用户节点进行邻居信息聚合，得到包含结构信息的节点向量表示。该过程使得每个用户的表示不仅反映其自身特征，也包含其在社交网络中的位置与关系。

3. **级联动态建模（LSTM）**：将历史激活序列对应的用户向量按时间顺序输入 LSTM 网络，得到当前时刻的隐藏状态，用于表示级联在前 t 个时间步的传播上下文。

4. **预测与评估**：将 LSTM 输出的级联上下文向量与 GNN 输出的所有节点表示进行匹配，计算每个候选用户被下一步激活的概率，从而形成对下一激活节点的预测分布，最后使用 MRR 与 Hits@K 的指标评估预测性能。

5.3 图神经网络传播

对于社交网络中的结构信息，模型则通过 GNN 融合社交结构信息。首先进行邻居聚合：$H_{\text{nbr}} = \tilde{A}H^{(0)}$。随后将节点自身表示与邻居表示拼接：$Z = [H^{(0)} \,\|\, H_{\text{nbr}}]$，并通过线性映射与 ReLU 激活函数得到更新后的节点向量：$H^{(1)} = \text{ReLU}(ZW)$。最后对于节点输出包含邻居信息的向量表示。

5.4 级联序列建模

对于时序的传播序列 $(u_1, \ldots, u_t)$，从 $H^{(1)}$ 中取出对应节点表示：

$$\mathbf{x}_k = H^{(1)}_{u_k}, \quad k = 1, \ldots, t$$

将该序列输入 LSTM：

$$\mathbf{h}_t = \mathrm{LSTM}(\mathbf{x}_1, \ldots, \mathbf{x}_t)$$

其中得到的隐藏状态 $\mathbf{h}_t$ 用于表示当前级联的上下文信息。

5.5 用户预测

模型通过计算上下文向量与图中所有节点向量的内积来进行打分：

$$\mathrm{score}(i) = \mathbf{h}_t^\top H_i^{(1)}, \quad i = 0, \ldots, N-1$$

并利用 softmax 得到下一用户的预测概率：

$$P(u_{t+1} = i \mid u_1, \ldots, u_t) = \frac{\exp(\mathrm{score}(i))}{\sum_{j=0}^{N-1} \exp(\mathrm{score}(j))}$$

5.6 训练与评估

模型学习的过程中采用交叉熵作为训练损失。对每个训练样本 $(u_1, \ldots, u_t, u_{t+1})$，损失定义为

$$\mathcal{L} = -\log P(u_{t+1} \mid u_1, \ldots, u_t)$$

最终目标函数为所有样本损失的平均值。在测试阶段，根据真实用户在预测排序中的名次 rank_i 计算：

$$\mathrm{MRR} = \frac{1}{M} \sum_{i=1}^{M} \frac{1}{\mathrm{rank}_i}$$

以及 Hits@K，即真实用户位于预测前 K 名的比例。

5.7 结果分析

模型经过训练后，在测试集上的评估结果为：

$$\mathrm{MRR} = 0.0665, \quad \mathrm{Hits@5} = 0.0870, \quad \mathrm{Hits@10} = 0.1304, \quad \mathrm{Hits@30} = 0.4565$$

其中，Hits@30 接近 0.46，意味着在接近一半的测试样本中，真实的下一传播用户能够出现在模型给出的前 30 个候选节点之内，表明模型能够有效缩小潜在传播用户的搜索空间。同时 MRR 值达到 0.0665，这表明依赖有限历史序列对下一节点进行预测问题的难度较大。[4]

从与已有研究的对比角度来看，同样比较对于微博数据的微观预测。已有文献中的数据就级联序列平均长度以及社交网络规模与本研究中较为接近。从实验结果看，本模型在 MRR 值和 Hits@k 的评价指标上均表现出明显优势。

6 总结与改进

6.1 实验总结

本研究围绕微博转发行为的宏观与微观预测问题，构建了基于转发树结构与统计特征的建模框架，并在真实社交媒体数据集上进行了可视化展示和实验验证。宏观层面上，研究利用初期转发量、时间序列特征以及用户节点特征对信息最终传播规模进行预测；微观层面上，则以转发树

和社交网络为基础，对节点级传播行为进行建模预测。实验结果表明，实现的模型能够在一定程度上捕捉微博传播的整体趋势与局部扩散模式，验证了基于图结构建模社交传播过程的可行性。

然而，由于数据规模、特征设计以及模型结构的限制，目前模型在复杂传播场景下仍存在一定的误差和不稳定性，尤其是在面对爆发式传播或不同内容类型差异较大的情况下，预测性能仍有提升空间。

6.2 改进方向

从数据的角度，当前实验使用的数据集规模较为有限，且转发总量分布范围有限。未来可以通过收集更多微博样本，覆盖更大转发规模区间的数据，以增强模型对不同传播强度场景的适应能力并提升泛化性能与鲁棒性。

宏观层面，模型对所有微博样本采用统一建模方式，忽略了不同传播范式之间的差异。对此可以在宏观层面引入“先分类、再预测”的两阶段框架，先采用 K-means 等聚类方法或自然语言处理的方法对具体微博的转发范式以及内容进行分类，总结这类别的转发树结构和信息传播方式，之后再在各类内部进行模型的学习预测。

而微观层面的预测目前主要依赖转发树的拓扑结构，而忽略了用户自身的异质性。然而在真实社交网络中，不同用户的自身特征对转发行为也具有重要影响。将用户节点的属性信息纳入模型有望显著提升对个体转发行为的预测精度。

6.3 小组分工

在本课题中王卓熙负责信息级联可视化工作，李哲伟负责微博传播级联宏观预测部分，章一诺负责微博传播级联微观预测部分，并共同讨论检查，报告一起完成。

提交的项目在 12 月 30 号展示过后对又爬取了一些数据，并删除了一些质量不高的数据，所以最后结果与展示 PPT 稍微有一点差别。

参考文献

[1] Zhengang Wang, Xin Wang, Fei Xiong, and Hongshu Chen. A survey of deep learning-based information cascade prediction. *Symmetry*, 16(11):1436, 2024.

[2] Jinghua Zhao, Jiale Zhao, and Juan Feng. Information diffusion prediction based on cascade sequences and social topology. *Computers and Electrical Engineering*, 109:108782, 2023.

[3] Huang Dewei, Wang Youguo, and Hou Haojie. 基于传播模式聚类与 xgboost 的社交网络流行度预测算法. *智能计算机与应用*, 15(5):21–27, 2025.

[4] Z. Wang and W. Li. Hierarchical diffusion attention network. In *Proceedings of the 28th International Joint Conference on Artificial Intelligence*, pages 3828–3834. International Joint Conferences on Artificial Intelligence, 2019.